

Lección 2: Tipos de datos y estructura de la información

Hans Sigrist

2026-03-12

En esta lección se analiza un conjunto de datos inspirado en la Encuesta Nacional de Empleo. Se estudian las nociones de observación, variable y niveles de medición, junto con la clasificación en variables categóricas y cuantitativas. Mediante herramientas básicas de R se exploran tablas, resúmenes descriptivos y representaciones gráficas. El objetivo es consolidar una comprensión estructural de los datos como fundamento del análisis estadístico posterior.

Tabla de contenidos

1	Origen institucional de los datos	2
2	Preparar el entorno y cargar datos	3
3	Explorar la estructura de los datos	3
4	Diccionario de variables	5
5	Resúmenes numéricos para variables cuantitativas	5
6	Tablas de frecuencias para variables categóricas	6
7	Filtrar datos para un análisis más específico	7
8	Relación entre dos variables cuantitativas: el diagrama de dispersión	8
9	Relación entre una variable numérica y una categórica: boxplots	9
10	(Mal) Ejemplo: forzar un gráfico inadecuado	11




Figura 1: Ilustración utilizada con fines educativos. Fuente: USF ClipArt Collection (University of South Florida).

1. Origen institucional de los datos

The simple graph has brought more information to the data analyst's mind than any other device.

— John Tukey

Los datos utilizados en esta lección (`empleo50`) son una versión didáctica simplificada de lo que habitualmente se obtiene a partir de encuestas oficiales de empleo. En Chile, la **Encuesta Nacional de Empleo (ENE)** es un estudio estadístico sistemático conducido por el **Instituto Nacional de Estadísticas (INE)**, que busca medir las condiciones del mercado laboral a nivel nacional. Esta encuesta recoge información individual sobre edad, región, estado laboral,

ingresos y horas trabajadas, entre otras variables, con el propósito de estimar indicadores como la tasa de ocupación y desempleo, identificar brechas laborales y apoyar el diseño de políticas públicas y programas sociales. El dataset `empleo50` simula la estructura principal de estos datos reales para facilitar el análisis de tipos de variables y la comprensión de la estructura de una matriz de datos sin necesidad de trabajar con bases originales completas.

2. Preparar el entorno y cargar datos

La organización y descripción efectiva de los datos es el primer paso en la mayoría de los análisis. Esta sección presenta la matriz de datos para organizarlos, así como la terminología sobre los diferentes tipos de datos que se utilizará a lo largo de este libro.

Primero cargamos las librerías necesarias para la lección y operatividad de R. En este caso, usaremos `dplyr` para manipular datos y `ggplot2` para graficar.

```
library(readr)
library(dplyr)
library(ggplot2)
library(knitr)
```

Los datos que utilizaremos corresponden a una muestra de 50 personas ocupadas en la Región de Valparaíso (fuente: Nueva Encuesta Nacional de Empleo, INE). Carguemos el archivo:

Exploración opcional en R (Jupyter / Colab)

Los estudiantes que deseen experimentar, pueden cargar la base directamente a su computador utilizando:

[empleo50.csv](#)

3. Explorar la estructura de los datos

Cada fila es una observación (persona) y cada columna una variable. Con `str()` vemos el tipo de cada variable:

```
str(empleo)
```

```
spc_tbl_ [49 x 8] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ region      : chr [1:49] "Metropolitana" "Biobío" "Valparaíso" "Araucanía" ...
 $ sexo        : chr [1:49] "Mujer" "Hombre" "Mujer" "Hombre" ...
```

```

$ edad          : num [1:49] 28 34 42 19 51 24 37 46 33 55 ...
$ nivel_educacional: chr [1:49] "Universitaria" "Técnica" "Media" "Básica" ...
$ estado_laboral  : chr [1:49] "Ocupado" "Ocupado" "Ocupado" "Desocupado" ...
$ tipo_contrato   : chr [1:49] "Indefinido" "Plazo fijo" "Informal" "N/A" ...
$ ingreso_mensual : num [1:49] 720000 560000 450000 0 890000 410000 520000 1050000 470000 0
$ horas_trabajo   : num [1:49] 40 38 35 0 42 40 36 45 38 0 ...
- attr(*, "spec")=
.. cols(
..   region = col_character(),
..   sexo = col_character(),
..   edad = col_double(),
..   nivel_educacional = col_character(),
..   estado_laboral = col_character(),
..   tipo_contrato = col_character(),
..   ingreso_mensual = col_double(),
..   horas_trabajo = col_double()
.. )
- attr(*, "problems")=<externalptr>

```

Aparecen variables numéricas (edad, ingreso_mensual) y categóricas (sexo, region). Esta distinción determina qué análisis podemos hacer.

Las primeras filas y la dimensión nos ayudan a entender su tamaño:

```
head(empleo, 5)
```

```

# A tibble: 5 x 8
  region      sexo  edad nivel_educacional estado_laboral tipo_contrato
  <chr>      <chr> <dbl> <chr>                <chr>         <chr>
1 Metropolitana Mujer    28 Universitaria      Ocupado      Indefinido
2 Biobío      Hombre   34 Técnica            Ocupado      Plazo fijo
3 Valparaíso  Mujer   42 Media              Ocupado      Informal
4 Araucanía   Hombre  19 Básica            Desocupado   N/A
5 Metropolitana Mujer   51 Universitaria      Ocupado      Indefinido
# i 2 more variables: ingreso_mensual <dbl>, horas_trabajo <dbl>

```

```
dim(empleo)
```

```
[1] 49  8
```

4. Diccionario de variables

Para saber qué mide cada columna la Tabla 1 es una descripción de cada variable de `empleo50`:

```
library(tibble)

dic_empleo <- tribble(
  ~variable, ~descripcion,
  "region",      "Región de residencia (categórica nominal).",
  "sexo",        "Sexo declarado (categórica nominal).",
  "edad",        "Edad en años (numérica discreta).",
  "nivel_educacional", "Nivel educacional (categórica ordinal).",
  "estado_laboral", "Condición laboral: Ocupado / Desocupado / Inactivo.",
  "tipo_contrato", "Tipo de contrato si está ocupado (NA si no aplica).",
  "ingreso_mensual", "Ingreso mensual en CLP (numérica).",
  "horas_trabajo",  "Horas trabajadas por semana (numérica).",
)

kable(dic_empleo, booktabs = TRUE)
```

Tabla 1: Variables y descripción para el conjunto de datos `empleo50`.

variable	descripcion
region	Región de residencia (categórica nominal).
sexo	Sexo declarado (categórica nominal).
edad	Edad en años (numérica discreta).
nivel_educacional	Nivel educacional (categórica ordinal).
estado_laboral	Condición laboral: Ocupado / Desocupado / Inactivo.
tipo_contrato	Tipo de contrato si está ocupado (NA si no aplica).
ingreso_mensual	Ingreso mensual en CLP (numérica).
horas_trabajo	Horas trabajadas por semana (numérica).

5. Resúmenes numéricos para variables cuantitativas

Para variables numéricas (cuantitativas), el resumen más útil suele ser el de cinco números: mínimo, primer cuartil, mediana, media, tercer cuartil y máximo. Lo obtenemos con `summary()`:

```
summary(empleo)
```

```

      region          sexo          edad  nivel_educacional
Length:49    Length:49    Min.   :19.00    Length:49
Class :character Class :character 1st Qu.:29.00    Class :character
Mode  :character Mode  :character Median :37.00    Mode  :character
                        Mean  :38.12
                        3rd Qu.:46.00
                        Max.   :61.00

estado_laboral  tipo_contrato ingreso_mensual  horas_trabajo
Length:49       Length:49    Min.   :      0    Min.   : 0.00
Class :character Class :character 1st Qu.: 420000    1st Qu.:36.00
Mode  :character Mode  :character Median : 540000    Median :40.00
                        Mean  : 541633    Mean  :33.39
                        3rd Qu.: 810000    3rd Qu.:40.00
                        Max.   :1050000    Max.   :45.00

```

Observa que `summary()` también nos da una tabla de frecuencias para las variables categóricas (como `sexo`). ¿Por qué crees que hace eso?

6. Tablas de frecuencias para variables categóricas

Cuando una variable es categórica, el resumen adecuado es una tabla de frecuencias. Podemos obtenerla con `table()`:

```
table(empleo$sexo)
```

```

Hombre  Mujer
     24     25

```

¿Cuántos hombres y cuántas mujeres hay en la muestra? Esta tabla responde esa pregunta de forma directa.

7. Filtrar datos para un análisis más específico

Supongamos que solo queremos estudiar a las personas ocupadas (que ya lo están) y además queremos quedarnos con quienes trabajan al menos 30 horas semanales. Usamos `filter()`:

```
empleo_ocup <- empleo %>%  
  filter(horas_trabajo >= 30)
```

¿Por qué es útil filtrar? Porque nos permite centrarnos en un subgrupo con características similares y evitar que los resultados se vean afectados por casos atípicos (como personas con trabajos de muy pocas horas).

Los datos de la Tabla 2 representan una **matriz de datos**, una forma práctica y común de organizarlos, especialmente si se recopilan en una hoja de cálculo. Cada fila de una matriz de datos corresponde a un caso único (unidad de observación) y cada columna a una variable.

En la práctica, es especialmente importante hacer preguntas aclaratorias para garantizar la comprensión de aspectos importantes de los datos. Por ejemplo, siempre es importante asegurarse de comprender el significado de cada variable y sus unidades de medida. Las descripciones de las variables de `empleo50` se presentan en la Tabla 2.

```
empleo4 <- empleo |>  
  mutate(id = row_number()) |>  
  slice(c(1,2,3, n())) |>  
  select(id, everything())  
  
kable(empleo4, booktabs = TRUE)
```

Tabla 2: Cuatro filas de la matriz de datos `empleo50`.

id	region	sexo	edad	nivel_educacional	estado_laboral	tipo_contrato	ingreso_mensual	horas_trabajo
1	Metropolitana	Mujer	28	Universitaria	Ocupado	Indefinido	720000	40
2	Biobío	Hombre	34	Técnica	Ocupado	Plazo fijo	560000	38
3	Valparaíso	Mujer	42	Media	Ocupado	Informal	450000	35
49	Metropolitana	Mujer	36	Técnica	Ocupado	Plazo fijo	600000	40

Para variables numéricas: `summary()`:

```
summary(select(empleo, edad, ingreso_mensual, horas_trabajo))
```

	edad	ingreso_mensual	horas_trabajo
Min.	:19.00	Min. : 0	Min. : 0.00
1st Qu.:	29.00	1st Qu.: 420000	1st Qu.:36.00
Median	:37.00	Median : 540000	Median :40.00
Mean	:38.12	Mean : 541633	Mean :33.39
3rd Qu.:	46.00	3rd Qu.: 810000	3rd Qu.:40.00
Max.	:61.00	Max. :1050000	Max. :45.00

Entrega mínimo, cuartiles, media y máximo. Es útil para detectar rangos y valores atípicos.

Para variables categóricas: `table()`:

```
table(empleo$region)
```

Antofagasta	Araucanía	Biobío	Coquimbo	Los Lagos
3	4	6	6	3
Los Ríos	Magallanes	Maule	Metropolitana	O'Higgins
3	3	4	8	3
Valparaíso				
6				

```
table(empleo$sexo)
```


Hombre	Mujer
24	25

8. Relación entre dos variables cuantitativas: el diagrama de dispersión

Ahora queremos explorar si existe relación entre edad e ingreso mensual. Para dos variables numéricas, el gráfico adecuado es un diagrama de dispersión (scatter plot):


```
empleo_ocup <- filter(empleo, estado_laboral == "Ocupado")

ggplot(empleo_ocup, aes(x = edad, y = ingreso_mensual)) +
  geom_point() +
  labs(title = "Edad vs Ingreso mensual")
```




Interpretación Cada punto es una persona. Observa si hay alguna tendencia: ¿a mayor edad, mayor ingreso? ¿Es una relación lineal? ¿Hay valores extremos?

9. Relación entre una variable numérica y una categórica: boxplots


Queremos comparar la distribución del ingreso mensual entre hombres y mujeres. Aquí tenemos una variable numérica (ingreso_mensual) y una categórica (sexo). El gráfico adecuado es el boxplot (diagrama de caja y bigotes):

```
ggplot(empleo_ocup, aes(x = nivel_educacional, y = ingreso_mensual)) +
  geom_boxplot()
```



¿Qué observas? Compara las medianas (la línea dentro de la caja), la dispersión (tamaño de las cajas) y la presencia de valores atípicos (puntos fuera de los bigotes). ¿Hay diferencias notables entre sexos?


```
ggplot(empleo_ocup, aes(x = nivel_educacional, y = horas_trabajo)) +  
  geom_boxplot()
```



10. (Mal) Ejemplo: forzar un gráfico inadecuado

Finalmente, probemos un gráfico que no es apropiado para el tipo de variables que tenemos. Queremos relacionar ingreso mensual (numérica) con horas de trabajo (también numérica), pero usamos un `geom_boxplot()` que está diseñado para una numérica y una categórica:

```
ggplot(empleo_ocup, aes(x = ingreso_mensual, y = horas_trabajo)) +  
  geom_boxplot()
```



¿Por qué es un mal ejemplo? Porque el boxplot agrupa por los valores únicos de x, y al ser ingreso_mensual una variable continua con muchos valores distintos, cada grupo tiene muy pocos datos (a menudo uno solo). El resultado es un gráfico confuso que no muestra ninguna estructura útil. Este error es común cuando no se piensa en la naturaleza de las variables antes de graficar.

11. Cuestionario Grupal (Portafolio): Tipos de Datos

Utiliza estos enlaces para contestar las siguientes preguntas:

- [Mercado laboral](#)
- [Ocupación y desocupación](#)

1. Según el documento “Metodología Encuesta Nacional de Empleo ENE 2020”, ¿Cuál es la edad de la población objetivo?
2. En referencia al mismo documento anterior, ¿Cómo define el Glosario del documento “Brecha de género”? Da un ejemplo que conozcas donde se presente esta brecha.
3. Lee atentamente este extracto:

“Tal y como se define en las normas internacionales, existen tres categorías principales, personas ocupadas, personas desocupadas y personas fuera de la fuerza de trabajo, por lo que la población activa está formada por las personas

en edad de trabajar que participan activamente en el mercado de trabajo, es decir la suma de las personas ocupadas y las desocupadas (personas cesantes y personas que buscan trabajo por primera vez). En conjunto, estos dos grupos de población en edad de trabajar representan la oferta de mano de obra para la producción de bienes y servicios a cambio de la remuneración o beneficio que existe en un país en un momento dado. Por otro lado, las personas fuera de la fuerza de trabajo son aquellas personas en edad de trabajar que durante el período de referencia no estaban ni en la ocupación ni en la desocupación”.

A partir de este extracto, explica quién es una persona fuera de la fuerza de trabajo y da un ejemplo concreto.

4. ¿Es lo mismo estar desempleado que estar fuera de la fuerza de trabajo?
5. ¿Por qué el último gráfico (ingreso vs horas) es un mal ejemplo? ¿Qué gráfico sería el adecuado?