

Lección 3: Tipos de variables

Hans Sigrist

2026-03-11

En esta lección se estudian los distintos tipos de variables estadísticas (numéricas y categóricas) y se introducen los conceptos de asociación, independencia y variables explicativa y respuesta.

Tabla de contenidos

1 Investigación sobre tipos de variables	1
2 Asociación $\neq$ Causalidad	4
3 Cuestionario Grupal	8

Built with Quarto v1.8.27 · R v4.5.2 · LaTeX v3.141592653-2.6-1.40.27 · openintro v2.0.0

Advertencia

Los datos utilizados en esta lección (`region30`) corresponden a una versión didáctica simplificada de la data `county` (`openintro`) que simula indicadores regionales en Chile. No representan datos oficiales del INE ni de ningún organismo público, y han sido contruidos únicamente con fines pedagógicos para el estudio de tipos de variables y relaciones estadísticas.

1. Investigación sobre tipos de variables

Primero cargar la librería `tidyverse` (si no está instalada aparecerá un error, en ese caso instalar primero con `install.package('tidyverse')`). `Tidyverse` es una colección de paquetes de R diseñados para la ciencia de datos. Todos los paquetes comparten una filosofía de diseño, una gramática y estructuras de datos subyacentes. Luego leer la base de datos `region30` creada



Figura 1: Ilustración utilizada con fines educativos. Fuente: USF ClipArt Collection (University of South Florida).

especialmente para esta lección. Finalmente usamos el comando `glimpse()` que nos da una visión transpuesta de los datos de manera que sea más fácil su lectura.

```
library(tidyverse)
region30 <- read_csv("../datos/region30.csv")
glimpse(region30)
```

```
Rows: 30
Columns: 8
$ region          <chr> "Norte_1", "Norte_2", "Norte_3", "Centro_1", ~
$ tasa_desempleo  <dbl> 8.4, 7.1, 9.3, 6.2, 5.8, 7.4, 10.2, 8.9, 7.6~
$ poblacion_total <dbl> 540000, 620000, 410000, 980000, 1120000, 870~
$ crecimiento_poblacional <dbl> 1.2, -0.5, 0.8, 1.5, 2.1, 0.4, -1.1, -
0.3, 0~
$ ingreso_mediano_hogar <dbl> 720000, 680000, 640000, 880000, 910000, 7600~
$ tasa_propietarios <dbl> 62.1, 59.3, 65.8, 55.4, 52.7, 60.2, 71.5, 68~
$ viviendas_multipiso <dbl> 38.4, 41.2, 32.5, 48.6, 50.1, 36.9, 21.4, 25~
$ nivel_educacional_mediano <chr> "Media completa", "Técnico superior", "Media~
```

Perfecto, Son 8 columnas y 30 filas. Verifiquemos los nombres de cada columna:

Advertencia

La variable `region` en la base `region30` no corresponde a la división político-administrativa oficial de Chile. Las categorías “Norte”, “Centro”, “Sur” y “Austral” representan macrozonas ficticias subdivididas artificialmente con fines didácticos. Esta construcción permite disponer de múltiples niveles categóricos para el análisis estadístico sin introducir interpretaciones geográficas, políticas o socioeconómicas reales. El objetivo es estudiar la clasificación de variables y las relaciones entre ellas, no describir la situación territorial efectiva del país.

Verifiquemos los nombres de las 8 columnas:

```
names(region30)
```

```
[1] "region"          "tasa_desempleo"
[3] "poblacion_total" "crecimiento_poblacional"
[5] "ingreso_mediano_hogar" "tasa_propietarios"
[7] "viviendas_multipiso" "nivel_educacional_mediano"
```

💡 Debes saber

Variable numérica continua puede tomar infinitos valores en un intervalo.

Variable numérica discreta representa conteos.

Variable categórica nominal categorías sin orden.

Variable categórica ordinal categorías con orden natural.


Cuidado con las variables numéricas, ya que si consideramos el **número** de celular, ciertamente estamos hablando de una variable numérica, pero a diferencia de la **tasa_desempleo** ésta última -también numérica- si es posible *sumar*, *restar* o *tomar un promedio* de sus valores. ¿Harías lo mismo con los números de celular?

Otra consideración muy especial de las variables, es que numéricamente se expresan en concordancia con su contexto, por ejemplo, si observas la variable **poblacion_total** te podrás dar cuenta que ocupa valores **enteros**. La razón, es más obvia de lo aparente. Justifícala.

2. Asociación $\neq$ Causalidad


En primero medio tuviste oportunidad de conocer la “nube de puntos” también llamada **scatterplot**. Usaremos este tipo de gráfico para exponer una situación muy comúnmente errónea:

```
ggplot(region30, aes(x = ingreso_mediano_hogar,
                    y = tasa_desempleo)) +
  geom_point() +
  labs(
    x = "Ingreso mediano del hogar",
    y = "Tasa de desempleo",
    title = "Ingreso vs Tasa de Desempleo"
  )
```



```
ggplot(region30, aes(x = viviendas_multipiso,
                     y = tasa_propietarios)) +
  geom_point() +
  labs(
    x = "Porcentaje viviendas multipiso",
    y = "Tasa de propietarios",
    title = "Multipiso vs Propietarios"
  )
```

Multipiso vs Propietarios



```
set.seed(123)
```

```
ingresos_tipicos <- round(rlnorm(60, meanlog = log(650), sdlog = 0.25))
```

```
ingresos_extremos <- c(5000, 7000, 12000)
```

```
ingresos <- c(ingresos_tipicos, ingresos_extremos)
```

```
length(ingresos)
```

```
[1] 63
```

```
summary(ingresos)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
398	578	668	1027	794	12000

```
media <- mean(ingresos)
```

```
mediana <- median(ingresos)
```


```
media
```

```
[1] 1026.524
```

```
mediana
```

```
[1] 668
```

```
hist(ingresos, breaks = 20, main = "Distribución de ingresos (con outliers)",  
     xlab = "Ingreso (miles de pesos)")  
abline(v = media, lwd = 2)  
abline(v = mediana, lwd = 2)  
legend("topright", legend = c("Media", "Mediana"), lwd = 2, bty = "n")
```



```
ingresos_sin_extremos <- ingresos_tipicos
```

```
mean(ingresos_sin_extremos)
```

```
[1] 677.85
```

```
median(ingresos_sin_extremos)
```

```
[1] 653.5
```

3. Cuestionario Grupal

1. Para cada variable que aparece en `names(region30)`, determine si es:
 - Numérica continua
 - Numérica discreta
 - Categórica nominal
 - Categórica ordinal

Para ello complete la siguiente tabla:

[illegible]

2. Como pudiste apreciar al usar `glimpse(region30)` la variable `región` no alcanza a mostrar todos sus campos. ¿Qué comando usarías para poder ver todos los valores de la variable `región`?

```
unique(region30$region)
```

[1]	"Norte_1"	"Norte_2"	"Norte_3"	"Centro_1"	"Centro_2"	"Centro_3"
[7]	"Sur_1"	"Sur_2"	"Sur_3"	"Austral_1"	"Austral_2"	"Austral_3"
[13]	"Centro_4"	"Centro_5"	"Norte_4"	"Sur_4"	"Austral_4"	"Centro_6"
[19]	"Norte_5"	"Sur_5"	"Centro_7"	"Austral_5"	"Norte_6"	"Centro_8"
[25]	"Sur_6"	"Austral_6"	"Centro_9"	"Norte_7"	"Sur_7"	"Centro_10"

```
sort(unique(region30$region))
```

```
[1] "Austral_1" "Austral_2" "Austral_3" "Austral_4" "Austral_5" "Austral_6"
[7] "Centro_1"  "Centro_10" "Centro_2"  "Centro_3"  "Centro_4"  "Centro_5"
[13] "Centro_6"  "Centro_7"  "Centro_8"  "Centro_9"  "Norte_1"   "Norte_2"
[19] "Norte_3"   "Norte_4"   "Norte_5"   "Norte_6"   "Norte_7"   "Sur_1"
[25] "Sur_2"     "Sur_3"     "Sur_4"     "Sur_5"     "Sur_6"     "Sur_7"
```

```
table(region30$region)
```

Austral_1	Austral_2	Austral_3	Austral_4	Austral_5	Austral_6	Centro_1	Centro_10
1	1	1	1	1	1	1	1
Centro_2	Centro_3	Centro_4	Centro_5	Centro_6	Centro_7	Centro_8	Centro_9
1	1	1	1	1	1	1	1
Norte_1	Norte_2	Norte_3	Norte_4	Norte_5	Norte_6	Norte_7	Sur_1
1	1	1	1	1	1	1	1
Sur_2	Sur_3	Sur_4	Sur_5	Sur_6	Sur_7		
1	1	1	1	1	1		

```
region30 |>
  count(region, sort = TRUE)
```

```
# A tibble: 30 x 2
  region      n
  <chr>    <int>
1 Austral_1    1
2 Austral_2    1
3 Austral_3    1
4 Austral_4    1
5 Austral_5    1
6 Austral_6    1
7 Centro_1     1
8 Centro_10    1
9 Centro_2     1
10 Centro_3    1
# i 20 more rows
```