

Lección 9: Probabilidad condicional y teorema de Bayes

Hans Sigrist

2026-05-10

Esta lección desarrolla la probabilidad condicional como herramienta para actualizar creencias a partir de nueva información. Se estudian las probabilidades marginales, conjuntas y condicionales usando tablas de contingencia, con dos ejemplos detallados: el uso de checklists en simulacros de vuelo y la inoculación contra la viruela en Boston en 1721. Se introduce la relación entre independencia y probabilidad condicional, los diagramas de árbol para procesos secuenciales, y el teorema de Bayes para invertir condicionales, incluyendo un ejemplo de mantenimiento aeronáutico y su simulación en R.

Tabla de contenidos

1	Objetivos de la lección	2
2	Probabilidad condicional: el corazón de la inferencia	2
3	Tablas de contingencia y los tres tipos de probabilidad	3
3.1	Ejemplo aeronáutico: checklist electrónico y errores en emergencia	3
3.2	Probabilidad marginal	3
3.3	Probabilidad conjunta	4
3.4	Probabilidad condicional	4
3.5	Ejemplo histórico: la viruela en Boston, 1721	5
4	Regla general de la multiplicación	6
5	Independencia y probabilidad condicional	7
5.1	Verificación con el ejemplo del checklist	7
5.2	El caso de los dados: un ejemplo de independencia genuina	7
6	Diagramas de árbol: organizar la información secuencial	8
6.1	Árbol del ejemplo de checklist	8
6.2	Árbol del ejemplo de Boston (viruela)	8
7	Teorema de Bayes: invertir la condicional	8
7.1	Ejemplo: detección de fisura interna en un motor de aeronave	9
7.2	Árbol de decisión para el ejemplo del sensor	10
7.3	Simulación en R	10
8	Síntesis de reglas	12



Figura 1: Torre de control de un aeropuerto. La toma de decisiones bajo incertidumbre se apoya en razonamiento condicional.

1. Objetivos de la lección

Al finalizar esta lección, serás capaz de:

- Distinguir entre **probabilidad marginal, conjunta y condicional**.
- Calcular probabilidades condicionales a partir de una **tabla de contingencia**.
- Aplicar la **regla general de la multiplicación** $P(A \text{ y } B) = P(A | B) \cdot P(B)$.
- Verificar si dos eventos son **independientes** usando la definición condicional.
- Construir e interpretar **diagramas de árbol** para organizar procesos secuenciales.
- Utilizar el **teorema de Bayes** para invertir el orden de una probabilidad condicional.
- Simular escenarios de pruebas diagnósticas con R y contrastar resultados empíricos con los teóricos.

2. Probabilidad condicional: el corazón de la inferencia

Hasta ahora hemos calculado probabilidades de eventos aislados o combinados bajo independencia. Pero en el mundo real casi nunca partimos de cero: **poseemos información previa** que modifica nuestras creencias. La probabilidad condicional captura exactamente esa idea: *¿cuál es la probabilidad de un evento A sabiendo que otro evento B ya ocurrió?*

i Definición: Probabilidad condicional

La **probabilidad condicional** de A dado B se denota $P(A | B)$ y se lee «probabilidad de A dado B ». Se calcula como

$$P(A | B) = \frac{P(A \text{ y } B)}{P(B)},$$

siempre que $P(B) > 0$. La barra vertical $|$ significa «dado que».

Intuitivamente, al conocer que B ocurrió **restringimos** nuestro espacio de posibilidades a aquellos resultados donde B es verdadero; dentro de ese subconjunto medimos la proporción de casos en que también ocurre A .

3. Tablas de contingencia y los tres tipos de probabilidad

Una **tabla de contingencia** (o tabla de doble entrada) es la herramienta natural para trabajar con probabilidades condicionales cuando tenemos dos variables categóricas. En la Lección 7 estudiamos su construcción; ahora añadimos el lenguaje formal de la probabilidad.

3.1. Ejemplo aeronáutico: checklist electrónico y errores en emergencia

Se registraron 320 simulacros de vuelo en los que se observó si la tripulación usaba un checklist electrónico (Sí / No) y si se cometía algún error en los procedimientos de emergencia (Sí / No). Los datos se resumen en la siguiente tabla de contingencia.

Tabla 1: Tabla de contingencia: uso de checklist electrónico vs. ocurrencia de errores en simulacros de emergencia ($n = 320$).

Checklist	Sin error	Con error	Total
Sí	112	48	160
No	64	96	160
Total	176	144	320

3.2. Probabilidad marginal

Es la probabilidad de **una sola variable**, ignorando la otra. Se obtiene dividiendo los totales de fila o columna por el gran total:

$$P(\text{checklist}) = \frac{160}{320} = 0,50, \quad P(\text{con error}) = \frac{144}{320} = 0,45.$$

3.3. Probabilidad conjunta

Es la probabilidad de que ocurran **simultáneamente** dos resultados, uno de cada variable. Se calcula dividiendo la celda correspondiente por el total general:

$$P(\text{checklist y sin error}) = \frac{112}{320} = 0,35.$$

3.4. Probabilidad condicional

Fijamos una condición y dentro de ese subgrupo medimos la frecuencia relativa del evento de interés. Por ejemplo, dentro de los 160 simulacros donde *se usó* checklist:

$$P(\text{sin error} \mid \text{checklist}) = \frac{112}{160} = 0,70.$$

De manera análoga, dentro de los 160 simulacros donde *no* se usó checklist:

$$P(\text{sin error} \mid \text{no checklist}) = \frac{64}{160} = 0,40, \quad P(\text{con error} \mid \text{no checklist}) = \frac{96}{160} = 0,60.$$

La diferencia entre las tasas de éxito —0,70 con checklist frente a 0,40 sin él— sugiere que el uso del checklist está **asociado** con una menor tasa de errores. Nótese que esta comparación es puramente observacional; en la sección sobre independencia formalizaremos si esa asociación es estadísticamente relevante.

```
cond_df <- data.frame(
  checklist = c("Con checklist", "Sin checklist"),
  prob_error = c(48 / 160, 96 / 160) # 0.30 y 0.60
)

ggplot(cond_df, aes(x = checklist, y = prob_error, fill = checklist)) +
  geom_col(width = 0.5) +
  geom_text(aes(label = percent(prob_error, accuracy = 1)),
    vjust = -0.4, size = 4.5, fontface = "bold") +
  scale_fill_manual(values = c("#0758E5", "#D7191C")) +
  scale_y_continuous(labels = percent_format(accuracy = 1),
    limits = c(0, 0.75)) +
  labs(
    x = "",
    y = "Probabilidad de error",
    title = "Probabilidad condicional de error en emergencia"
  ) +
  theme_minimal(base_size = 13) +
  theme(legend.position = "none")
```

Probabilidad condicional de error en emergencia




Figura 2: Probabilidad de error condicionada al uso de checklist. La barra azul representa $P(\text{con error} \mid \text{checklist}) = 0,30$ y la roja $P(\text{con error} \mid \text{no checklist}) = 0,60$.

3.5. Ejemplo histórico: la viruela en Boston, 1721

En 1721 la ciudad de Boston sufrió un brote de viruela. Los médicos de la época creían que la **inoculación** —exponer a la persona a la enfermedad en forma controlada— reducía la probabilidad de muerte. Se dispone de datos de 6.224 personas expuestas al virus; cada caso registra si fue inoculada y si sobrevivió.

Tabla 2: Tabla de contingencia: inoculación y resultado en el brote de viruela de Boston, 1721 ($n = 6.224$).

Inoculado	Vivió	Murió	Total
Sí	238	6	244
No	5136	844	5980
Total	5374	850	6224

Las probabilidades condicionales relevantes se obtienen dividiendo cada celda por el total de su fila:

$$P(\text{vivió} \mid \text{inoculado}) = \frac{238}{244} \approx 0,975, \quad P(\text{vivió} \mid \text{no inoculado}) = \frac{5136}{5980} \approx 0,859.$$

$$P(\text{murió} \mid \text{inoculado}) = \frac{6}{244} \approx 0,025, \quad P(\text{murió} \mid \text{no inoculado}) = \frac{844}{5980} \approx 0,141.$$

La tasa de mortalidad de los inoculados ($\sim 2,5\%$) es aproximadamente **seis veces menor** que la de los no inoculados ($\sim 14,1\%$), lo que sugiere una fuerte asociación entre la inoculación y la supervivencia. No obstante, como la inoculación fue voluntaria (estudio observacional), no podemos concluir causalidad directa; podrían existir variables de confusión como el acceso a mejores cuidados médicos.

Tasa de mortalidad por viruela según inoculación Boston, 1721




Figura 3: Tasa de mortalidad condicional al estado de inoculación. La diferencia entre ambas barras ilustra la asociación observacional entre inoculación y supervivencia.

4. Regla general de la multiplicación

La definición de probabilidad condicional puede reordenarse algebraicamente para obtener la **regla general de la multiplicación**, también llamada regla del producto:

! Regla general de la multiplicación

Para cualquier par de eventos A y B :

$$P(A \text{ y } B) = P(A | B) \cdot P(B).$$

Esta fórmula es válida **independientemente** de si A y B son independientes o no. Cuando son independientes, $P(A | B) = P(A)$ y la fórmula se reduce a $P(A \text{ y } B) = P(A) \cdot P(B)$, recuperando la regla de la Lección 8.

Además, dado un mismo condicionante B , los eventos A y su complemento A^c cubren todo el espacio, de modo que:

$$P(A | B) + P(A^c | B) = 1 \implies P(A | B) = 1 - P(A^c | B).$$

Verificación con los datos de Boston. Solo conociendo que el 96,08 % de las personas no fueron inoculadas y que el 85,89 % de las no inoculadas sobrevivió, podemos reconstruir la probabilidad conjunta:

$$P(\text{no inoculado y vivió}) = P(\text{vivió} | \text{no inoculado}) \times P(\text{no inoculado}) = 0,8589 \times 0,9608 \approx 0,8252,$$

lo que coincide con el valor de la tabla ($5136/6224 \approx 0,8252$). ✓

5. Independencia y probabilidad condicional

En la Lección 8 definimos dos eventos como **independientes** si el conocimiento de uno no afecta la probabilidad del otro. Ahora podemos expresar esa idea en términos condicionales:

i Definición: Independencia mediante probabilidad condicional

Dos eventos A y B son **independientes** si y solo si

$$P(A | B) = P(A).$$

De manera equivalente, $P(A \text{ y } B) = P(A) \cdot P(B)$. Ambas condiciones son equivalentes y cualquiera puede usarse para verificar independencia.

Si A y B son independientes, saber que B ocurrió no cambia en nada la probabilidad de A ; el condicionamiento es «inútil». En cambio, si $P(A | B) \neq P(A)$, existe una **dependencia** entre los eventos.

5.1. Verificación con el ejemplo del checklist

Comprobemos si «usar checklist» y «no cometer errores» son independientes:

$$P(\text{sin error}) = \frac{176}{320} = 0,55.$$

$$P(\text{sin error} | \text{checklist}) = 0,70 \neq 0,55.$$

Como las dos probabilidades difieren, los eventos **no son independientes**: usar el checklist modifica (en este caso, aumenta) la probabilidad de no cometer errores.

Podemos verificar lo mismo con la regla del producto:

$$P(\text{checklist}) \times P(\text{sin error}) = 0,50 \times 0,55 = 0,275 \neq 0,35 = P(\text{checklist y sin error}).$$

La desigualdad confirma la dependencia.

5.2. El caso de los dados: un ejemplo de independencia genuina

Sea X el resultado del primer dado e Y el del segundo (dados honestos, lanzamientos independientes). Usando la fórmula condicional:

$$P(Y = 1 | X = 1) = \frac{P(Y = 1 \text{ y } X = 1)}{P(X = 1)} = \frac{1/36}{1/6} = \frac{1}{6} = P(Y = 1).$$

El conocimiento de X no modifica la probabilidad de Y , como esperamos de procesos físicamente separados. Este razonamiento también explica la **falacia del jugador**: si en una ruleta han salido cinco veces seguidas negro, la probabilidad de rojo en el siguiente giro sigue siendo 18/37 (o 18/38 en ruleta americana), porque cada giro es independiente de los anteriores.

6. Diagramas de árbol: organizar la información secuencial

Cuando un proceso puede descomponerse en etapas —donde cada etapa depende de la anterior— los **diagramas de árbol** permiten visualizar las probabilidades condicionales y calcular probabilidades conjuntas multiplicando a lo largo de cada camino.

Regla de construcción: las ramas primarias llevan probabilidades **marginales**; las ramas secundarias (y terciarias, si las hay) llevan probabilidades **condicionales** respecto al camino recorrido. El producto de las probabilidades a lo largo de un camino es la **probabilidad conjunta** de ese resultado final.

6.1. Árbol del ejemplo de checklist

```

      +--- Sin error (0,70)  ->  0,50 x 0,70 = 0,350
Checklist (0,50)-|
      +--- Con error  (0,30)  ->  0,50 x 0,30 = 0,150

      +--- Sin error (0,40)  ->  0,50 x 0,40 = 0,200
No checklist (0,50)-|
      +--- Con error  (0,60)  ->  0,50 x 0,60 = 0,300
                                   -----
                                   Suma total: 1,000
```

Nótese que la suma de las cuatro probabilidades conjuntas es 1, como debe ser para una distribución completa del espacio muestral.

6.2. Árbol del ejemplo de Boston (viruela)

```

      +--- Vivió (0,9754)  ->  0,0392 x 0,9754 = 0,03824
Inoculado (0,0392)|
      +--- Murió (0,0246)  ->  0,0392 x 0,0246 = 0,00096

      +--- Vivió (0,8589)  ->  0,9608 x 0,8589 = 0,82523
No inoculado (0,9608)|
      +--- Murió (0,1411)  ->  0,9608 x 0,1411 = 0,13557
                                   -----
                                   Suma total: 1,00000
```

El árbol de Boston también permite «invertir» la condicional mediante Bayes (ver sección siguiente): si sabemos que una persona **murió**, ¿cuál es la probabilidad de que haya sido inoculada? El árbol nos da todos los ingredientes necesarios.

7. Teorema de Bayes: invertir la condicional

A menudo conocemos $P(B | A)$ pero necesitamos $P(A | B)$. El **teorema de Bayes** proporciona la fórmula exacta para realizar esa inversión.

! Teorema de Bayes

Si $A_1, A_2, \dots, A_k$ son todos los resultados posibles de la primera variable (mutuamente excluyentes y exhaustivos) y B es un resultado de la segunda, entonces

$$P(A_i | B) = \frac{P(B | A_i) \cdot P(A_i)}{\sum_{j=1}^k P(B | A_j) \cdot P(A_j)}.$$

El denominador es simplemente $P(B)$, la probabilidad **marginal** de B , expresada como suma ponderada de todas las formas en que B puede ocurrir.

La clave intuitiva es la siguiente: la probabilidad marginal $P(A_i)$ se denomina **probabilidad a priori** («antes de observar B »); una vez que observamos B , la actualizamos a $P(A_i | B)$, la **probabilidad a posteriori**. Esta idea de *actualización de creencias* es el fundamento de la estadística bayesiana.

7.1. Ejemplo: detección de fisura interna en un motor de aeronave

En un taller de mantenimiento aeronáutico se sabe que solo el 1 % de los motores presentan una fisura interna peligrosa. Un sensor de ultrasonido tiene las siguientes características:

- **Sensibilidad:** $P(\text{alarma} | \text{fisura}) = 0,95$. Detecta correctamente la fisura en el 95 % de los motores que la tienen.
- **Tasa de falsos positivos:** $P(\text{alarma} | \text{sano}) = 0,08$. Produce una alarma en el 8 % de los motores sanos.

Si un motor elegido al azar dispara la alarma, ¿cuál es la probabilidad de que realmente tenga la fisura?

Paso 1: identificar las probabilidades dadas.

$$P(\text{fisura}) = 0,01, \quad P(\text{sano}) = 0,99.$$

$$P(\text{alarma} | \text{fisura}) = 0,95, \quad P(\text{alarma} | \text{sano}) = 0,08.$$

Paso 2: calcular la probabilidad marginal de alarma (denominador de Bayes).

$$P(\text{alarma}) = P(\text{alarma} | \text{fisura}) P(\text{fisura}) + P(\text{alarma} | \text{sano}) P(\text{sano})$$

$$= 0,95 \times 0,01 + 0,08 \times 0,99 = 0,0095 + 0,0792 = 0,0887.$$

Paso 3: aplicar Bayes.

$$P(\text{fisura} | \text{alarma}) = \frac{P(\text{alarma} | \text{fisura}) P(\text{fisura})}{P(\text{alarma})} = \frac{0,0095}{0,0887} \approx 0,107.$$

A pesar de que el sensor es bastante preciso, **menos del 11 %** de los motores que disparan la alarma tienen realmente una fisura. ¿Por qué? Porque la condición (fisura) es muy rara: el 1 % de prevalencia significa que existen muchos motores sanos que generan falsas alarmas en términos absolutos, aun cuando la tasa de falso positivo individual sea

solo del 8 %. Este fenómeno, llamado **negligencia de la tasa base** (*base rate neglect*), es uno de los resultados más contraintuitivos de la probabilidad y aparece en contextos tan variados como pruebas médicas de enfermedades raras, filtros de spam o reconocimiento de rostros.

7.2. Árbol de decisión para el ejemplo del sensor

```

      +--- Alarma (0,95) -> 0,01 x 0,95 = 0,00950
Fisura (0,01) -|
      +--- No alarma (0,05) -> 0,01 x 0,05 = 0,00050

      +--- Alarma (0,08) -> 0,99 x 0,08 = 0,07920
Sano (0,99) -|
      +--- No alarma (0,92) -> 0,99 x 0,92 = 0,91080
                                     -----
                                     Suma total: 1,00000

```

$$P(\text{alarma}) = 0,00950 + 0,07920 = 0,08870 \checkmark$$

$$P(\text{fisura} \mid \text{alarma}) = \frac{0,00950}{0,08870} \approx 0,107 \checkmark$$

7.3. Simulación en R

La simulación permite verificar empíricamente el resultado teórico y observar cómo la **Ley de los Grandes Números** hace que la proporción observada converja al valor teórico.

```

set.seed(314)
n <- 50000

# 1. Generamos el estado del motor: 1 = fisura (1%), 0 = sano (99%)
motor <- rbinom(n, size = 1, prob = 0.01)

# 2. Determinamos si la alarma suena:
#   - Si hay fisura: P(alarma) = 0.95 (sensibilidad)
#   - Si está sano: P(alarma) = 0.08 (tasa de falsos positivos)
prob_alarma <- ifelse(motor == 1, 0.95, 0.08)
alarma <- rbinom(n, size = 1, prob = prob_alarma)

# 3. Ensamblamos el data frame con etiquetas legibles
df_motor <- data.frame(
  fisura = factor(motor, levels = c(0, 1), labels = c("Sano", "Fisura")),
  alarma = factor(alarma, levels = c(0, 1), labels = c("No", "Alarma"))
)

# 4. Estimamos P(fisura | alarma) a partir de la simulación
tab <- table(df_motor)
P_sim <- tab["Fisura", "Alarma"] / sum(tab[, "Alarma"])

# 5. Preparamos el subconjunto de motores con alarma para visualizar

```

```

df_alarma <- df_motor |>
  filter(alarma == "Alarma") |>
  count(fisura) |>
  mutate(prop = n / sum(n))

ggplot(df_alarma, aes(x = "Alarma", y = prop, fill = fisura)) +
  geom_col(width = 0.35, color = "white", linewidth = 0.8) +
  geom_text(
    aes(label = percent(prop, accuracy = 0.1)),
    position = position_stack(vjust = 0.5),
    size = 5, color = "white", fontface = "bold"
  ) +
  scale_fill_manual(values = c("Fisura" = "#D7191C", "Sano" = "gray55")) +
  scale_y_continuous(labels = percent_format()) +
  labs(
    x      = "",
    y      = "Proporción",
    fill   = "",
    title  = "Composición de motores que dispararon la alarma",
    subtitle = paste0(
      "Simulado: P(Fisura | Alarma) = ", percent(P_sim, accuracy = 0.1),
      " | Teorico: P(Fisura | Alarma) aprox. 10,7%"
    )
  ) +
  theme_minimal(base_size = 13) +
  theme(axis.text.x = element_blank())

```




Figura 4: Simulación del proceso de detección de fisura ($n = 50.000$ motores). La barra muestra la composición de los motores que activaron la alarma: en rojo los que tienen fisura (verdaderos positivos) y en gris los sanos (falsos positivos). La proporción roja estima $P(\text{fisura} | \text{alarma})$.

La diferencia entre el valor simulado y el teórico es pequeña porque $n = 50.000$ es un tamaño muestral grande. Con $n = 100$ la discrepancia sería mucho mayor; con $n = 1.000.000$ sería prácticamente nula. Esto es precisamente lo que garantiza la **Ley de los Grandes Números**: a medida que $n \rightarrow \infty$, la proporción observada converge casi seguramente a la probabilidad teórica.

8. Síntesis de reglas

Concepto	Fórmula	Condición de validez
Probabilidad condicional	$P(A B) = \frac{P(A \cap B)}{P(B)}$	$P(B) > 0$
Regla del producto (general)	$P(A \cap B) = P(A B) \cdot P(B)$	Siempre
Regla del producto (independiente)	$P(A \cap B) = P(A) \cdot P(B)$	$A \perp B$
Independencia (equivalencia)	$P(A B) = P(A)$	$P(B) > 0$
Complemento condicional	$P(A B) = 1 - P(A^c B)$	$P(B) > 0$
Suma de condicionales	$\sum_i P(A_i B) = 1$	$\{A_i\}$ partición
Teorema de Bayes	$P(A_i B) = \frac{P(B A_i)P(A_i)}{\sum_j P(B A_j)P(A_j)}$	$\{A_j\}$ partición, $P(B) > 0$

9. Cuestionario grupal

Responde cada pregunta mostrando los cálculos completos y justificando las reglas que aplicas.

- Checklist y errores.** Con los datos de la tabla de contingencia de esta lección, calcula:
 - $P(\text{sin error} | \text{no checklist})$
 - $P(\text{checklist} | \text{sin error})$ — nota que aquí «inviertes» la condición; usa la definición de probabilidad condicional.
 - ¿Son independientes los eventos «usar checklist» y «no cometer errores»? Prueba con *ambas* condiciones equivalentes de la definición de independencia.
- Árbol de decisiones.** Dibuja el diagrama de árbol completo para el ejemplo del checklist. Escribe en cada rama las probabilidades marginales, condicionales y conjuntas. Verifica que la suma de las probabilidades conjuntas es 1.
- Motor y alarma.** Supón que la prevalencia de fisura aumenta al 5 % y la tasa de falsos positivos se reduce al 5 % (sensibilidad igual, 95 %). Calcula $P(\text{fisura} | \text{alarma})$ con estos nuevos parámetros. ¿Por qué cambia tanto la probabilidad respecto al ejemplo original?
- Viruela en Boston, 1721.** A partir de los datos de la Tabla 2:
 - Calcula $P(\text{vivió} | \text{inoculado})$ y $P(\text{vivió} | \text{no inoculado})$ usando la fórmula de probabilidad condicional.
 - ¿La inoculación y el resultado son independientes? Prueba con la regla del producto.

c) ¿Por qué no podemos concluir que la inoculación *causó* la mayor supervivencia? ¿Qué tipo de estudio sería necesario?

5. **Resultados de examen.** En un curso, el 13 % de los estudiantes obtiene A en el parcial. De estos, el 47 % obtiene A en el final; de los que no obtuvieron A en el parcial, solo el 11 % obtiene A en el final. Si un estudiante elegido al azar obtiene A en el final, ¿cuál es la probabilidad de que también haya obtenido A en el parcial? Construye el diagrama de árbol y aplica el teorema de Bayes.
6. **Congestión en plataforma (Bayes con tres causas).** Un aeropuerto pequeño tiene tres tipos de eventos que pueden causar congestión en la plataforma: mantenimiento de pista (15 % de los días), llegada de vuelos militares (5 % de los días) y ningún evento especial (80 % de los días). Cuando hay mantenimiento, la congestión ocurre el 60 % de las veces; con vuelos militares, el 90 %; sin eventos, solo el 10 %. Si hoy hay congestión, ¿cuál es la probabilidad de que se deba a llegada de vuelos militares? *Nota: este problema tiene la misma estructura que el ejercicio del estacionamiento universitario del libro de referencia; compara los resultados.*

Prof. Hans Sigrist — Colegio Portaliano, San Felipe